

ĐỀ BÀI DỰ ÁN CUỐI KÌ SUDO CODE 2026 — VÒNG 1

Harness Agent hỗ trợ Call Center E-commerce (Telesale)

Ngữ cảnh liên tục qua nhiều phiên & nhiều kênh · Tự đánh giá và cải tiến theo thời gian

A. BỐI CẢNH & CASE STUDY

Phần lớn đơn hàng online giá trị trung bình—cao tại Việt Nam không chốt được trên web/app mà phải qua cuộc gọi tư vấn. Mỗi telesale gọi 80–150 cuộc/ngày, và một khách thường cần **nhiều lần chạm** mới quyết định. Vấn đề: hầu hết hệ thống call center được thiết kế **stateless** — kết thúc cuộc gọi là mất ngữ cảnh.

Case 1 — Khách gọi lại nhưng hệ thống coi như người lạ (bài toán lỗi)

Chị Hoa được tư vấn 9 phút mua máy lọc không khí: phòng 25m², có trẻ nhỏ, ngân sách 5tr, chốt model X giá 4.890.000đ, khuyến mãi tới cuối tuần. Chị nói *"để hỏi ông xã rồi gọi lại"*. Hai ngày sau chị gọi lại, rơi vào nhân viên khác — kịch bản lặp lại từ đầu: *"Dạ chị quan tâm sản phẩm nào ạ? Nhà mình bao nhiêu m²? Ngân sách khoảng nhiều ạ?"*. Nhân viên mới tư vấn model Y, báo giá 5.200.000đ vì không biết khuyến mãi cũ. Chị Hoa mất niềm tin: *"Sao mỗi người nói một kiểu vậy em?"*

Hệ quả: đơn lẻ ra chốt sau 2 cuộc thì mất 5–10 cuộc · chi phí phục vụ/đơn tăng 3–5 lần · 40–60% thời lượng cuộc gọi bị đốt để thu thập lại thông tin đã có · khách bỏ đi sau cuộc thứ 3.

Thiếu: bộ nhớ dài hạn theo khách hàng vượt ranh giới phiên + cơ chế nhận diện khách gọi lại và tái nạp ngữ cảnh.

Case 2 — Ngữ cảnh phân mảnh đa kênh: mỗi kênh biết một nửa sự thật

Anh Tuấn nhắn Fanpage hỏi giày, được báo sale 690k. Anh inbox Zalo OA hỏi đổi size, nhân viên khác trả lời. Anh xem livestream rồi gọi hotline. Nhân viên hotline **không thấy gì cả**, báo giá niêm yết 790k. *"Ủa bên em nhắn Facebook báo anh 690k mà?"* — nhân viên không xác minh được, hoặc chấp nhận đại dù chương trình đã hết.

Hệ quả: báo giá/chính sách không nhất quán giữa các kênh → khiếu nại, mất uy tín · khách lặp lại nhu cầu 3–4 lần · nhân viên phải mở song song 4–5 tab trong lúc đang nói chuyện với khách.

Thiếu: hồ ngữ cảnh hợp nhất theo danh tính khách hàng (nhận diện qua SĐT / Zalo ID / FB ID) + cơ chế giải quyết mâu thuẫn giữa các nguồn.

Case 3 — Bàn giao mù: giữa AI và người, giữa ca này và ca kia

Voicebot lọc lead nói chuyện 4 phút, khai thác được: khách mua cho mẹ bị tiểu đường, quan tâm sản phẩm A nhưng lo tương tác thuốc. Khách hỏi câu ngoài phạm vi → chuyển máy. Nhân viên nhận máy: *"Dạ em nghe, mình cần hỗ trợ gì ạ?"* — 4 phút khai thác bốc hơi. Trải nghiệm chuyển máy thành trải nghiệm tệ nhất hành trình, tệ hơn cả không có bot. Tương tự khi: ca sáng hẹn *"chiều gọi lại"* nhưng chiều là ca khác trực · nhân viên phụ trách nghỉ việc · khách gọi đổi size/địa chỉ nhưng không ai biết trạng thái đơn.

Hệ quả: hài lòng sau chuyển máy thấp hẳn · người thật phải nghe lại 5–10 phút ghi âm, hoặc bỏ qua luôn · đơn COD bị hoàn vì không ai chủ động xác nhận lại.

Thiếu: bản tóm tắt bàn giao (handoff brief) có cấu trúc + bộ nhớ chia sẻ giữa các agent, cả AI lẫn người.

Case 4 — Kịch bản đóng băng: không học được gì từ hàng nghìn cuộc gọi

Trung tâm 40 nhân viên, ~4.000 cuộc/ngày, QA chỉ nghe ngẫu nhiên ~2%. Call script do trưởng nhóm viết 8 tháng trước, cập nhật bằng cảm tính. Cùng một phản đối "*đắt quá em ơi*", có người chốt được 40%, có người 8% — nhưng không ai biết cách nào hiệu quả hơn vì không có dữ liệu đối chiếu giữa cách xử lý và kết quả chốt đơn. Câu khách hay hỏi ("*đang cho con bú dùng được không?*") không có trong kịch bản → mỗi người trả lời một kiểu. Khuyến mãi hết hạn vẫn được báo suốt 2 tuần.

Hệ quả: hệ thống hôm nay và 6 tháng trước giống hệt nhau về chất lượng · 98% tín hiệu chất lượng bị bỏ phí · rủi ro cam kết sai không được phát hiện.

Thiếu: cơ chế đánh giá tự động chấm 100% cuộc gọi + vòng lặp cải tiến biến kết quả chốt đơn thành cập nhật cho kịch bản, tài liệu và bộ nhớ.

B. ĐỀ BÀI

Xây dựng Harness Agent hỗ trợ Call Center bán hàng online (Telesale) có khả năng duy trì ngữ cảnh liên tục qua nhiều phiên & nhiều kênh, tự đánh giá và cải tiến theo thời gian.

1. **Xử lý dữ liệu hội thoại tiếng Việt** — giọng nói (file ghi âm cuộc gọi) và văn bản (chat, teencode, viết tắt) → ngữ cảnh có cấu trúc, truy vấn được.
2. **Duy trì bộ nhớ khách hàng xuyên phiên:** khách gọi lại thì nhận diện được, nạp đúng ngữ cảnh cũ, mở đầu bằng *xác nhận tiếp nối* thay vì hỏi lại từ đầu.
3. **Thiết kế agent harness:** vòng lặp nhận thức → truy hồi → lập kế hoạch → gọi tool → quan sát → ghi nhớ, có guardrail và fallback.
4. **Đo lường được chính mình:** bộ đánh giá tự động, chứng minh *bằng số* rằng hệ thống tốt hơn baseline không-có-bộ-nhớ.
5. **Cải tiến từ feedback mà không huấn luyện lại mô hình:** cập nhật tài liệu, bộ nhớ, ngân hàng ví dụ, kịch bản xử lý phản đối.

Định hướng chấm điểm: Toàn bộ mô hình đều dùng bản có sẵn. Điểm đến từ **cách nhóm thiết kế dữ liệu, kiến trúc, cách đo đạc và cách cải tiến**. Một hệ thống chạy ở chế độ chat text, dùng model nhỏ, nhưng có bộ nhớ hoạt động đúng và có số liệu chứng minh — sẽ được điểm cao hơn một hệ thống voice hào nhoáng mà không đo được gì.

*Các thuật ngữ in nghiêng trong đề (harness, guardrail, RAG, MCP, A2A, baseline...) và công thức tính từng chỉ số đều được giải thích chi tiết ở **Phụ lục** cuối đề.*

C. YÊU CẦU CỤ THỂ

Hai mức độ hoàn thành

M1 Cơ bản — bắt buộc. Làm đủ M1 là đã đạt yêu cầu vòng 1.

M2 Nâng cao — khuyến khích. Làm được sẽ nổi bật rõ so với mặt bằng. *Chỉ làm M2 khi M1 đã chạy*

ổn định.

Ngoài hai mức trên, mục **G** có danh sách *tính năng cộng điểm thưởng* dành cho nhóm còn dư thời gian.

C.1. Dữ liệu & xử lý tiếng Việt

Hạng mục dataset	M1	M2
Số cuộc hội thoại (dạng transcript)	≥ 120	≥ 250
Trong đó có audio (thu thật hoặc sinh bằng TTS)	≥ 40 cuộc / ≥ 1 giờ	≥ 100 / ≥ 3 giờ
Khách hàng đa phiên (≥ 2 cuộc gọi cùng 1 khách)	≥ 30 khách	≥ 60 (có khách ≥ 3 phiên)
Khách có cả cuộc gọi + chat (đa kênh)	≥ 10 khách	≥ 30 khách
Ngành hàng · giọng vùng miền	1 ngành · 2 miền	3 ngành · 3 miền
Audio có nhiễu (đường phố, sóng yếu)	—	≥ 20%
Catalog sản phẩm + chính sách (giá, KM, đổi trả, ship)	≥ 30 SKU	≥ 100 SKU

Điều kiện tiên quyết: dataset các nhóm sẽ tự đi tìm, ưu tiên nguồn tiếng Việt và **phải có nhóm khách đa phiên** — đây là trọng tâm bài toán, dataset chỉ gồm các cuộc gọi rời rạc sẽ không chấm được.

Được phép sinh toàn bộ dữ liệu bằng LLM đóng vai + TTS — đây là cách làm hoàn toàn chấp nhận được, không bị trừ điểm.

Nghiêm cấm dùng ghi âm khách hàng thật chưa ẩn danh.

Persona cần có

M1 (≥3): khách do dự cần hỏi người nhà · khách so giá · khách đã mua gọi lại đòi size/khiếu nại.

M2 thêm: khách hỏi nhiều không mua · khách gọi lần 3 đã hết kiên nhẫn.

Pipeline xử lý:

Hạng Mục	M1 Cơ bản	M2 Nâng cao
Voice	dùng ASR tiếng Việt có sẵn (Whisper / PhoWhisper — không cần train) để chuyển file ghi âm thành text · báo cáo WER/CER trên ≥ 20 file chuẩn hóa số bắt buộc: "bốn triệu tám trăm chín mươi" → 4.890.000, "hai trăm bốn chín k" → 249.000, số điện thoại, ngày hẹn gọi lại.	Tách người nói (diarization) agent/khách · sửa lỗi ASR bằng từ điển tên sản phẩm ("Xiao Mi" → Xiaomi, "sai z eo" → size L) · xử lý audio nhiễu · xử lý theo luồng (streaming).
Text	chuẩn hóa teencode / viết tắt / không dấu ("sp nay co ship cod k a") và code-switching	—

	Việt–Anh (size, ship, sale, order, inbox).	
Trích xuất có cấu trúc	intent · sản phẩm quan tâm, size/màu, <i>mức giá đã báo</i> , thời điểm hẹn gọi lại, người ra quyết định (" <i>để hỏi chồng</i> ") · kết quả cuộc gọi (chốt / hẹn lại / từ chối).	thêm: loại phản đối + cách xử lý · sentiment · <i>cam kết đã hứa với khách</i> .
PII	che số điện thoại / CCCD / địa chỉ khi lưu log và khi gửi ra model ngoài (regex là đủ).	tokenization để nghiệp vụ vẫn dùng được + xóa toàn bộ dữ liệu 1 khách theo yêu cầu.


Thiết kế lớp bộ nhớ (phần quan trọng nhất của mục này):

Mức	Tầng	Nội dung / ví dụ
M1	Working	Ngữ cảnh lượt thoại hiện tại — khách vừa nói gì, đang chờ xác nhận gì
M1	Episodic	Tóm tắt từng cuộc gọi — " <i>Cuộc 1 (12/03): tư vấn model X, báo 4.89tr, khách hẹn hỏi chồng</i> "
M1	Profile	Sự thật bền vững về khách — phòng 25m², có con nhỏ, ngân sách ~5tr
M2	Semantic / KB	Giá, tồn kho, khuyến mãi <i>còn hiệu lực</i> , chính sách đổi trả (dùng RAG)

M1 Phải xử lý được: **ghi gì / không ghi gì** (tránh nhồi rác vào bộ nhớ) và **khách đổi ý** ("*thôi anh lấy màu trắng*" — thông tin cũ phải bị vô hiệu, không được để hai giá trị mâu thuẫn cùng tồn tại).

M2 Thêm: hết hạn theo thời gian (khuyến mãi cũ, ý định mua đã nguội) · truy vết nguồn gốc mỗi mẫu ký ức (đến từ cuộc gọi nào) · chống đầu độc bộ nhớ khi khách cung cấp thông tin sai.

C.2. Harness Agent (trọng tâm)



Hạng Mục	M1 Cơ bản	M2 Nâng cao
Session Continuity - tính năng bắt buộc số 1	1. Nhận diện khách gọi lại qua số điện thoại. 2. Sinh "Call Brief" nạp cho agent	Phát hiện khuyến mãi đã hết hạn / hàng đã hết và xử lý khéo, không báo lại giá

	ngay trước khi bắt máy: khách là ai, đã gọi mấy lần · sản phẩm đã tư vấn + <i>giá / khuyến mãi đã báo</i> · rào cản còn tồn đọng ("<i>chờ hỏi chồng</i>") · hành động đề xuất tiếp theo. 3. Mở đầu bằng xác nhận tiếp nối: <i>"Dạ em chào chị Hoa, hôm 12/03 bên em có tư vấn chị mẫu máy lọc X cho phòng 25m² giá ưu đãi 4.890.000đ. Chị đã trao đổi với anh nhà chưa ạ, hay còn băn khoăn điểm nào để em hỗ trợ thêm?"</i> 4. Không hỏi lại thông tin đã có — nếu cần xác minh thì phải là câu hỏi xác nhận, không phải câu hỏi mở.	cũ · xử lý khách gọi từ số lạ.
Tích hợp công cụ — agent gọi được ≥ 3 tool (mock có schema rõ ràng là đủ, không cần hệ thống thật):	<code>crm.get_customer</code> · <code>catalog.search</code> + <code>inventory.check</code> · <code>order.create</code> . Quan trọng nhất: giá phải lấy từ tool, agent không được tự bịa giá hay khuyến mãi .	<code>pricing.get_quote</code> (chỉ trả KM còn hiệu lực) · <code>order.status/update</code> · <code>schedule.callback</code> .
Phải trình bày và bảo vệ được	đưa gì vào prompt và cắt gì khi ngữ cảnh dài · khi nào cần gọi tool và khi nào không · xử lý lỗi (tool timeout, ASR trả ra rác, LLM trả sai định dạng — <i>hệ thống nói gì với khách lúc đó?</i>) · khi nào chuyển cho người thật và bàn giao kèm thông tin gì.	xử lý khách ngắt lời (barge-in) · nén/tóm tắt ngữ cảnh khi vượt cửa sổ token.

Chế độ hoạt động & hiệu năng:

Chỉ tiêu	M1	M2
Chế độ vận hành	Chat text + xử lý file ghi âm offline	Voice gần real-time
Thời gian nạp Call Brief	≤ 5 giây	≤ 3 giây
Thời gian phản hồi mỗi lượt (p95)	Chat: TTFT p95 ≤ 3 giây; Total Latency p95 ≤ 8 giây.	Voice: TTFA p95 ≤ 2.5 giây
Số phiên đồng thời (demo)	1	≥ 2

Lưu ý quan trọng: **M1** không yêu cầu voicebot nói chuyện real-time. Chế độ chat text + đọc file ghi

âm là đủ để chứng minh toàn bộ ý tưởng về bộ nhớ và harness. *Đừng dồn cả 4 tuần vào việc ghép voice pipeline rồi không còn thời gian làm phần bộ nhớ và đánh giá.*

C.3. Áp dụng MCP hoặc A2A (chọn ít nhất một, giải thích lý do chọn)

Hướng 1 — MCP (Model Context Protocol): đóng gói hệ thống nghiệp vụ thành MCP server thay vì hard-code trong agent.

M1 Xây ≥ 2 MCP server, trong đó **bắt buộc có mcp-memory** (đọc/ghi bộ nhớ khách hàng) — đây là server thú vị nhất của bài này. Server còn lại tự chọn: mcp-catalog hoặc mcp-crm .

M2 Thêm mcp-order , mcp-knowledge (RAG chính sách/FAQ), phân quyền theo tool (tool nào được ghi dữ liệu). **Hướng 2 — A2A / Multi-agent:** nhiều agent chuyên biệt phối hợp với nhau.

Mức	Agent	Trách nhiệm
M1	Orchestrator / Router	Điều phối, quyết định agent nào xử lý lượt thoại này
M1	Context & Memory Agent	Nhận diện khách, dựng Call Brief, quyết định ghi gì vào bộ nhớ
M1	Sales Advisor Agent	Tư vấn sản phẩm dựa trên profile khách
M2	Policy & Compliance Agent	Chặn bịa giá / cam kết sai chính sách / lộ thông tin cá nhân
M2	QA / Evaluator Agent	Chấm điểm cuộc gọi theo rubric (mục C.4)

Yêu cầu chung: các agent phải **thật sự chia sẻ trạng thái và chuyển giao nhiệm vụ cho nhau**, không phải một chuỗi prompt gọi tuần tự rồi đặt tên cho oai. Nhóm phải chỉ ra được ít nhất một tình huống cụ thể mà tách agent giúp hệ thống tốt hơn.

C.4. Đánh giá hệ thống (trọng tâm)

M1 Phải có **script đánh giá chạy được bằng một lệnh** và in ra bảng chỉ số — không chấp nhận số liệu chép tay trong slide. *Công thức tính từng chỉ số xem Phụ lục A; mẫu định dạng kịch bản test xem Phụ lục B.*

Bộ test:

M1 ≥ 20 kịch bản đa phiên (mỗi kịch bản gồm 2–3 cuộc gọi liên tiếp cùng 1 khách, có kỳ vọng rõ ràng ở từng cuộc) + ≥ 5 kịch bản khó, chọn trong: khách đổi ý giữa chừng · khách đưa thông tin mâu thuẫn với phiên trước · khách đòi áp *khuyến mãi đã hết hạn* · khách hỏi thông tin *không có trong tài liệu* (agent phải nói không biết, không được bịa).

M2 ≥ 40 kịch bản + agent **đóng vai khách hàng** (customer simulator) để chạy đánh giá tự động lặp lại được, có mức kiên nhẫn giảm dần mỗi lần bị hỏi lại.

Chỉ số bắt buộc M1 — chỉ 5 con số, nhưng phải đo đúng:

Chỉ số	Ý nghĩa
Repeat-Question Rate ★	% câu hỏi lặp lại thông tin hệ thống đã biết — KPI số 1 của đề bài
Context Carryover Rate	% thông tin quan trọng từ phiên trước được dùng đúng ở phiên sau
Task Success Rate	% kịch bản đạt được mục tiêu đề ra

Hallucination Rate	% phát ngôn bịa thông tin giá / khuyến mãi / chính sách
WER / CER	Độ chính xác ASR, kèm độ chính xác riêng cho <i>số tiền</i> và <i>số điện thoại</i>

M2 Thêm: Calls-to-Close · Tool-Call Accuracy · Recall@k của phần RAG · độ trễ p50/p95 · chi phí ước tính mỗi cuộc gọi.

M1 Baseline bắt buộc: phải chạy song song một phiên bản **không có bộ nhớ** (mỗi cuộc gọi độc lập, giống hệ thống call center hiện tại) trên *cùng bộ test*, và trình bày bảng so sánh chênh lệch. Không có baseline thì mọi con số đều vô nghĩa.

Ngưỡng kỳ vọng: Repeat-Question Rate giảm $\geq 40\%$ so với baseline · Task Success Rate $\geq 70\%$ · Hallucination Rate về giá $\leq 5\%$.

M2 Dùng LLM để chấm điểm (LLM-as-a-judge): phải có rubric rõ ràng (không chấm kiểu "cho điểm 1–10" chung chung) và **đối chiếu với người**: nhóm tự chấm tay ≥ 20 mẫu, báo cáo tỷ lệ đồng thuận với LLM.

C.5. Cơ chế cải tiến theo thời gian

Ràng buộc: KHÔNG được huấn luyện lại / fine-tune mô hình. Mọi cải tiến phải đến từ dữ liệu, bộ nhớ, prompt/kịch bản và cách điều phối. Ràng buộc này có chủ đích: buộc nhóm giải bài toán bằng **thiết kế hệ thống**, không phải bằng GPU.

Nguồn feedback — **M1** thu ít nhất 2 trong số: kết quả cuộc gọi (chốt / hẹn lại / từ chối) · điểm chấm tự động từ bộ đánh giá · nút 👍/👎 của nhân viên trên từng gợi ý mà hệ thống đưa ra · việc khách phải nhắc lại thông tin.

Cơ chế cải tiến — **M1** hiện thực ít nhất 1, **M2** ít nhất 2:

- M1 Knowledge Gap Loop (dễ nhất, nên chọn đầu tiên)** — câu hỏi agent không trả lời được sẽ tự động ghi lại thành danh sách thiếu sót → bổ sung vào tài liệu → tự động thêm vào bộ test để lần sau không tái phạm.
- M1 Exemplar Bank** — cuộc gọi chốt đơn thành công được lưu thành ví dụ mẫu, lần sau gặp tình huống tương tự thì lấy ra làm few-shot.
- M2 Reflection** — sau mỗi cuộc gọi, agent tự viết "bài học rút ra" có cấu trúc, được kiểm tra rồi mới ghi vào bộ nhớ.
- M2 A/B test kịch bản** — chạy song song 2 biến thể cách xử lý phản đối, so sánh tỷ lệ chốt, giữ cái tốt hơn.

M1 Chứng minh bằng số: chạy hệ thống ở vòng 0, thu feedback, áp dụng cải tiến, chạy lại vòng 1 *trên cùng một bộ test giữ nguyên*, và trình bày chênh lệch. Chỉ cần **2 vòng** là đủ.

M2 3 vòng trở lên + phân tích trường hợp cải tiến *gây hại*.

M1 An toàn: thay đổi nào cần người duyệt trước khi áp dụng? **M2** Chống việc hệ thống học nhầm rằng "hứa đại cho khách chốt đơn" là chiến lược tốt · cơ chế quay lui khi chỉ số tụt.

C.6. Sản phẩm & Demo

Hạng Mục	M1 Cơ bản	M2 Nâng cao
Giao diện	Web đơn giản là đủ, không cần đẹp, khung hội thoại · Call Brief hiện ra khi khách gọi lại · dòng thời gian bộ nhớ của khách (đã tương tác gì, khi nào).	Thêm: gợi ý câu trả lời cho nhân viên (chế độ copilot) · cảnh báo khi agent sắp cam kết sai · dashboard hiển thị các chỉ số ở C.4.
Kịch bản demo chạy trực tiếp	Cuộc 1: khách liên hệ lần đầu, được tư vấn, có báo giá + khuyến mãi, hẹn " <i>để hỏi người nhà</i> ". Cuộc 2 (vài ngày sau, cùng khách): hệ thống nhận diện khách, nạp Call Brief, mở đầu bằng xác nhận tiếp nối, không hỏi lại bất kỳ thông tin nào đã có, và chốt đơn.	Cuộc 3: khách gọi lại sau khi đã đặt hàng để đổi size / hỏi vận đơn — hệ thống biết đơn nào và cập nhật bộ nhớ tương ứng.

Kèm theo: chạy **script đánh giá trực tiếp** để cho thấy con số so với baseline.

D. RÀNG BUỘC

- **Không cần huấn luyện mô hình.** Dùng model có sẵn (local hoặc API). Điểm đến từ thiết kế dữ liệu, kiến trúc, đánh giá và cải tiến — không đến từ điểm benchmark của model.
- **ASR phải chạy được local M1** (Whisper bản nhỏ chạy được trên laptop hoặc Google Colab miễn phí). LLM được phép dùng API để nhóm không bị chặn bởi phần cứng. Chạy được toàn bộ LLM local là *điểm thưởng*, không bắt buộc.
- **Không dùng ghi âm khách hàng thật** chưa ẩn danh và chưa có sự đồng ý — vi phạm là loại.
- **Toàn bộ trải nghiệm bằng tiếng Việt tự nhiên**, đúng ngữ điệu bán hàng Việt Nam (ạ/vâng/à, xưng hô anh/chị/em theo ngữ cảnh).
- Mã nguồn chạy được theo hướng dẫn trong README.
- Agent **không được giả vờ là người thật** nếu khách hỏi trực tiếp.

Ba lỗi khiến nhóm mất điểm nhiều nhất:

- (1) dồn 3 tuần vào ghép voice real-time rồi không kịp làm bộ nhớ và đánh giá — *M1 không cần voice*;
- (2) để đến tuần cuối mới làm phần đánh giá, dẫn tới không có baseline và không có số liệu;
- (3) dataset toàn cuộc gọi rời rạc, không có khách đa phiên, nên không demo được đúng bài toán.

E. GỢI Ý CÔNG NGHỆ & LỘ TRÌNH

Combo gợi ý cho nhóm mới bắt đầu (chạy được nhanh, ít rủi ro): `faster-whisper` (ASR) + LLM qua

API + ChromaDB (bộ nhớ & RAG) + LangGraph hoặc tự viết vòng lặp bằng Python thuần + FastAPI + giao diện Streamlit . *Tự viết vòng lặp harness bằng Python thuần hoàn toàn được chấp nhận và thường dễ giải thích khi phản biện hơn là dùng framework.*

- **ASR tiếng Việt:** PhoWhisper · Whisper / faster-whisper · wav2vec2-vi
- **TTS tiếng Việt (để sinh dataset):** edge-tts (*miễn phí, dễ nhất*) · viXTTS · F5-TTS-Vietnamese
- **Tách người nói:** Silero VAD · pyannote.audio
- **LLM:** API (Claude, GPT, Gemini) · local: Qwen, Llama, Gemma, Vistral, PhoGPT — chạy bằng Ollama / vLLM **Embedding tiếng Việt:** bge-m3 · multilingual-e5 · Vietnamese-SBERT
- **Bộ nhớ / Vector DB:** ChromaDB · Qdrant · pgvector · SQLite (cho profile) · Mem0, Zep (framework có sẵn) **Agent orchestration:** LangGraph · CrewAI · AutoGen · Pydantic AI · hoặc Python thuần
- **MCP:** Anthropic MCP SDK · FastMCP
- **Đánh giá:** RAGAS · DeepEval · promptfoo · Langfuse (theo dõi) — hoặc tự viết script chấm
- **Backend / Frontend:** FastAPI · Streamlit (*nhANH NHẤT*) · Next.js/React

Lộ trình gợi ý 4 tuần — bám theo thứ tự này để không bị vỡ tiến độ:

- **Tuần 1:** sinh dataset (ưu tiên làm nhóm khách đa phiên trước) · dựng pipeline ASR + chuẩn hóa số · thiết kế schema bộ nhớ.
- **Tuần 2:** vòng lặp harness + 3 tool mock · **Session Continuity & Call Brief** — đây là trái tim của bài, xong sớm sẽ nhàn.
- **Tuần 3:** bộ test + script đánh giá + chạy baseline không-bộ-nhớ · **đo số lần đầu tiên.**
- **Tuần 4:** 1 cơ chế cải tiến + đo lại vòng 2 · giao diện · quay demo · viết báo cáo.

F. SẢN PHẨM NỘP

Hạng mục	Yêu cầu
Mã nguồn	Repo có README, hướng dẫn cài đặt và chạy, script khởi tạo dữ liệu
Dataset	Bộ dữ liệu + mô tả ngắn: cách sinh, phân bố, hạn chế, cách xử lý thông tin cá nhân
Tài liệu kiến trúc	Sơ đồ hệ thống & vòng lặp harness · thiết kế bộ nhớ · danh sách tool · các quyết định thiết kế và lý do
Báo cáo đánh giá	Bảng chỉ số, so sánh với baseline không-bộ-nhớ , kết quả trước/sau khi cải tiến, phân tích ≥ 10 trường hợp hệ thống làm sai
Video demo	5–8 phút, bắt buộc có kịch bản 2 cuộc gọi ở mục C.6
Website	Phải có những tính năng bắt buộc
Slide	Tối đa 15 slide

G. TIÊU CHÍ ĐÁNH GIÁ VÒNG 1

#	Tiêu chí	Mô tả	Hệ số
1	Dữ liệu & xử lý tiếng Việt	Dataset đủ và hợp lý, <i>đặc biệt là nhóm khách đa phiên</i> · chất lượng ASR và chuẩn hóa số tiền/SDT · chất lượng trích xuất thông tin có cấu trúc · xử lý thông tin cá nhân	12%

2	Kiến trúc & Harness Agent	Vòng lặp harness rõ ràng, có kiểm soát · Session Continuity: nhận diện khách gọi lại + Call Brief + không hỏi lại (bắt buộc) · thiết kế bộ nhớ phân tầng, xử lý khách đổi ý · guardrail chống bịa giá, fallback khi lỗi	22%
3	Áp dụng MCP / A2A	Độ phù hợp của kiến trúc với bài toán · chất lượng tích hợp tool (đúng schema, xử lý lỗi) · giải thích thuyết phục lý do chọn · nếu multi-agent: các agent có phối hợp thật sự không	15%
4	Đánh giá hệ thống	Script đánh giá chạy được, tái lập được · bộ test đa phiên + ca khó · đủ 5 chỉ số M1 · có baseline không-bộ-nhớ để so sánh · phân tích lỗi nghiêm túc	15%
5	Cơ chế cải tiến	Vòng lặp feedback hoạt động thật · chứng minh cải thiện bằng số qua 2 vòng trên cùng bộ test · có kiểm soát của con người trước khi áp dụng thay đổi	13%
6	Trải nghiệm & demo	Giao diện dùng được cho telesale thật · hội thoại tiếng Việt tự nhiên · demo thuyết phục · ước lượng tác động kinh doanh · tính sáng tạo ngoài yêu cầu	13%
7	Khả năng mở rộng & chi phí	Kiến trúc mở rộng được theo số khách hàng · ước tính chi phí mỗi cuộc gọi · khả năng thêm ngành hàng/kênh mới	5%
8	Trình bày & phản biện	Trình bày rõ ràng, logic, trung thực về hạn chế · trả lời phản biện chính xác	5%
TỔNG			100%

Điểm thưởng (tối đa +5%) — chỉ tính khi phần M1 đã hoàn chỉnh:

- Voicebot nói chuyện real-time mượt, có xử lý khách ngắt lời.
- Nhận diện khách qua giọng nói (voiceprint) khi gọi từ số lạ · xử lý được ca hai người dùng chung một số điện thoại.
- Chạy được toàn bộ hệ thống (kể cả LLM) trên máy local với phần cứng phổ thông.
- Tối ưu kịch bản/prompt tự động (DSPy, TextGrad, GEPA hoặc tự viết vòng lặp) · ablation chỉ ra cơ chế cải tiến nào thực sự tạo khác biệt.
- Tầng bộ nhớ Playbook: tự đúc kết cách xử lý phản đối hiệu quả theo từng persona.
- Phát hiện realtime khi nhân viên cam kết sai chính sách và cảnh báo ngay trong cuộc gọi. Dự đoán xác suất chốt đơn và đề xuất thời điểm gọi lại tối ưu · phát hiện drift khi phân phối câu hỏi thay đổi. Kết nối MCP server có sẵn ngoài đời (Google Calendar cho lịch gọi lại, Google Sheets/Notion cho bảng giá).

Điểm trừ nặng:

- Không có Session Continuity (khách gọi lại vẫn bị hỏi từ đầu) → mất phần lớn hạng mục 2
- Không có baseline so sánh → mất phần lớn hạng mục 4
- Số liệu báo cáo không tái lập được bằng code → coi như không có số liệu
- Dùng dữ liệu khách hàng thật trái phép → **loại**.

PHỤ LỤC A — CÁCH TÍNH CÁC CHỈ SỐ BẮT BUỘC

Phần này quy định **cách tính thống nhất** để ban giám khảo so sánh được giữa các nhóm. Nhóm nào tính khác phải nêu rõ và giải thích lý do trong báo cáo.

A.1. Repeat-Question Rate (RQR) — tỷ lệ hỏi lại ★ KPI số 1

Đo cái gì: agent có đang hỏi khách những điều mà hệ thống *đã biết từ trước cuộc gọi* hay không. Đây là con số phản ánh trực tiếp nỗi đau ở Case 1.

$$RQR = (\text{Số câu hỏi thừa}) / (\text{Tổng số câu hỏi agent đặt ra}) \times 100\%$$

Thế nào là "câu hỏi thừa": mỗi câu hỏi của agent được gán về một *slot thông tin* (ngân sách, diện tích phòng, size, màu, địa chỉ, sản phẩm quan tâm...). Nếu slot đó **đã có giá trị hợp lệ trong bộ nhớ trước khi cuộc gọi bắt đầu** thì câu hỏi đó bị tính là thừa.

Ba trường hợp KHÔNG tính là thừa:

Câu xác nhận — "*Dạ chị vẫn lấy size L đúng không ạ?*" Đây là hành vi đúng, được khuyến khích. Chỉ câu hỏi mở ("*Chị mặc size mấy ạ?*") mới bị tính.

Thông tin đã hết hạn theo quy tắc TTL nhóm tự định nghĩa (ví dụ địa chỉ giao hàng quá 6 tháng thì hỏi lại là hợp lý).

Thông tin thực sự mới, chưa từng xuất hiện ở phiên trước.

Cách gán nhãn tự động: trong file kịch bản test, khai báo sẵn trường `must_not_ask` liệt kê các slot mà agent không được hỏi lại (xem Phụ lục B). Script đánh giá chỉ cần đối chiếu câu hỏi của agent với danh sách này — không cần chấm tay.

Ví dụ tính: ở cuộc gọi thứ 2, agent đặt 6 câu hỏi, trong đó 3 câu hỏi lại về diện tích phòng, ngân sách, và có trẻ nhỏ hay không — cả 3 slot này đều đã có trong profile.

$$RQR = 3 / 6 = 50\%$$

So với baseline: đề yêu cầu *giảm* $\geq 40\%$, hiểu là **giảm tương đối**:

$$\text{Mức giảm} = (RQR_baseline - RQR_hệ_thống) / RQR_baseline \times 100\%$$

Ví dụ: baseline 83%, hệ thống 50% $\rightarrow (83-50)/83 = 39.8\% \rightarrow$ CHƯA đạt ngưỡng 40%

A.2. Context Carryover Rate (CCR) — tỷ lệ mang ngữ cảnh sang phiên sau

Đo cái gì: ngược với RQR. RQR phạt việc hỏi thừa; CCR thưởng việc *dùng đúng* thông tin cũ. Cần cả hai vì một agent im lặng không hỏi gì cũng đạt RQR = 0% nhưng vô dụng.

$$CCR = (\text{Số fact được sử dụng đúng}) / (\text{Số fact bắt buộc mang sang}) \times 100\%$$

Cách xác định: mỗi kịch bản test khai báo trước danh sách `must_carry_over` — những thông tin bắt buộc phải được mang sang phiên sau (ví dụ: sản phẩm đã tư vấn, giá đã báo, rào cản còn tồn đọng). **Thế nào là "sử dụng đúng":** fact đó xuất hiện ở *đúng chỗ có ý nghĩa* — trong lời thoại của agent, hoặc trong tham số của một lệnh gọi tool. Mỗi fact chỉ tính tối đa 1 lần.

Cảnh báo khi thiết kế chỉ số này: đừng để agent "cày điểm" bằng cách đọc vẹt toàn bộ thông tin cũ vào câu chào — "*Dạ chào chị Hoa, phòng chị 25m², chị có con nhỏ, ngân sách 5 triệu, hôm trước em báo 4.890.000đ, chị bảo hỏi chồng...*". Đó là hành vi spam, không phải hội thoại tốt. Nhóm nên

bổ sung quy tắc chấm: fact chỉ được tính khi nó phục vụ đúng mục đích ở lượt thoại đó.

A.3. Task Success Rate (TSR) — tỷ lệ hoàn thành nhiệm vụ

$TSR = (\text{Số kịch bản đạt}) / (\text{Tổng số kịch bản}) \times 100\%$

Quan trọng — chấm nhị phân bằng assertion, không chấm cảm tính. Mỗi kịch bản khai báo trước điều kiện thành công dưới dạng kiểm tra được bằng code, ví dụ:

Agent đã gọi `order.create` với đúng SKU, đúng size, đúng giá đã cam kết ở phiên trước. Hoặc: agent đã gọi `schedule.callback` với thời điểm khách nêu.

Hoặc (ca khó): agent **không** gọi tool nào và trả lời rằng mình không có thông tin.

Nếu điều kiện thành công phụ thuộc vào chất lượng lời thoại (khó assert), nhóm dùng LLM-as-a-judge với rubric — nhưng phải nêu rõ kịch bản nào chấm bằng assertion, kịch bản nào chấm bằng judge.

A.4. Hallucination Rate (HR) — tỷ lệ bịa thông tin

Đơn vị đếm là "claim", không phải lượt thoại. Một *claim kiểm chứng được* là bất kỳ phát ngôn nào của agent khẳng định một dữ kiện có thể đối chiếu với nguồn sự thật (catalog, bảng giá, chính sách, tồn kho, thời gian giao hàng).

$HR = (\text{Số claim sai}) / (\text{Tổng số claim kiểm chứng được}) \times 100\%$

Ví dụ: agent nói "*Dạ máy này giá 4.890.000đ, đang có khuyến mãi tặng bộ lọc, giao trong 2 ngày ạ*" → 3 claim. Nếu catalog ghi giá 5.200.000đ và khuyến mãi đã hết hạn → 2 claim sai. Riêng lượt này $HR = 2/3$.

Lưu ý: không tính các câu xã giao, câu hỏi, hay ý kiến chủ quan ("*mẫu này hợp với nhà có trẻ nhỏ lắm ạ*") — chỉ tính dữ kiện đối chiếu được. Đề tách riêng ngưỡng cho **claim về giá và khuyến mãi ($\leq 5\%$)** vì đây là loại sai gây thiệt hại tiền thật.

A.5. WER / CER và độ chính xác thực thể

WER (Word Error Rate) — tỷ lệ lỗi ở mức từ, tính bằng khoảng cách chỉnh sửa giữa câu ASR nhận ra và câu đúng (ground truth):

$WER = (S + D + I) / N \times 100\%$

S = số từ bị thay sai · D = số từ bị thiếu · I = số từ bị thêm thừa

N = tổng số từ trong câu đúng

CER (Character Error Rate) — công thức tương tự nhưng đếm trên ký tự. *Với tiếng Việt nên báo cáo cả hai:* WER rất nhạy với lỗi dấu thanh (sai một dấu là sai cả từ), trong khi CER phản ánh mức độ sai thực tế mượt hơn. **Chuẩn hóa trước khi tính** — phải nêu rõ trong báo cáo đã chuẩn hóa những gì: chuyển thường, bỏ dấu câu, chuẩn hóa số. Cùng một hệ thống, chuẩn hóa khác nhau có thể cho WER chênh nhau 5–10%, nên đây là điều bắt buộc phải công bố.

Entity Accuracy — quan trọng hơn WER trong bài này:

$\text{Entity Accuracy} = (\text{Số thực thể trích xuất đúng hoàn toàn}) / (\text{Tổng số thực thể}) \times 100\%$

Áp dụng cho **số điện thoại và số tiền**, so khớp chính xác tuyệt đối (exact match) sau khi chuẩn hóa. Lý do tách riêng: WER 15% nghe có vẻ ổn, nhưng nếu lỗi rơi đúng vào một chữ số của số điện thoại thì đơn hàng đó hỏng hoàn toàn. Một hệ thống WER cao nhưng Entity Accuracy cao vẫn dùng được; ngược lại thì không.

A.6. Bảng so sánh bắt buộc trong báo cáo

Chỉ số	Baseline (không bộ nhớ)	Hệ thống của nhóm	Chênh lệch
Repeat-Question Rate ★	...	...	giảm ...%
Context Carryover Rate	...	...	...
Task Success Rate	...	...	...
Hallucination Rate (giá & KM)	...	...	...
Số lượt thoại trung bình / kịch bản	...	...	...

Baseline và hệ thống phải chạy trên **cùng bộ test, cùng model, cùng tham số** — chỉ khác duy nhất ở việc có nạp bộ nhớ phiên trước hay không. Đây là điều kiện để phép so sánh có ý nghĩa.

PHỤ LỤC B — MẪU ĐỊNH DẠNG KỊCH BẢN TEST

Đây là gợi ý định dạng, nhóm được tự thiết kế lại. Điểm mấu chốt: **mọi thứ dùng để chấm điểm đều phải khai báo trước trong file**, để script đánh giá tự chấm được mà không cần người ngồi nghe.

```
{
  "scenario_id": "SC-07",
  "persona": "khach_do_du_hoi_nguoi_nha",
  "customer_phone": "0982xxxxxx",

  "call_1": {
    "customer_goal": "hoi may loc khong khi cho phong 25m2, ngan sach 5tr",
    "facts_established": {
      "room_area_m2": 25,
      "has_children": true,
      "budget_vnd": 5000000,
      "product_advised": "SKU-AP-X",
      "price_quoted_vnd": 4890000,
      "promo_code": "GIFT-FILTER",
      "promo_expiry": "2026-03-16",
      "blocker": "can hoi chong"
    },
    "expected_outcome": "hen_goi_lai"
  },

  "call_2": {
    "days_later": 2,

    "must_carry_over": [ // dùng để tính Context Carryover Rate
      "product_advised", "price_quoted_vnd", "room_area_m2", "blocker"
    ],

    "must_not_ask": [ // dùng để tính Repeat-Question Rate
      "room_area_m2", "budget_vnd", "has_children", "product_advised"
    ],

    "success_if": { // dùng để tính Task Success Rate
      "tool_called": "order.create",
      "args_match": { "sku": "SKU-AP-X", "price_vnd": 4890000 }
    }
  },
}
```

```
"ground_truth_facts": { // dùng để tính Hallucination Rate
  "price_vnd": 4890000,
  "promo_active": true,
  "in_stock": true,
  "delivery_days": 2
}
```

Vì sao nên làm file test trước khi code agent: khi bộ test đã định nghĩa rõ *"không được hỏi lại cái gì"* và *"thành công nghĩa là gì"*, việc thiết kế bộ nhớ và harness trở nên rõ ràng hơn hẳn — nhóm biết chính xác mình đang tối ưu cho cái gì. Đây cũng là lý do lộ trình ở mục E đặt phần đánh giá ở tuần 3 chứ không phải tuần cuối.

PHỤ LỤC C — GIẢI THÍCH THUẬT NGỮ

C.1. Thuật ngữ AI / kỹ thuật

Agent	Chương trình dùng LLM để tự quyết định hành động: đọc ngữ cảnh → chọn việc cần làm → gọi công cụ → xem kết quả → làm tiếp, lặp cho đến khi xong nhiệm vụ.
Harness	Phần "khung xương" bao quanh LLM: code điều khiển vòng lặp, quản lý ngữ cảnh đưa vào prompt, gọi tool, bắt lỗi, áp guardrail, ghi nhớ. LLM là bộ não; harness là toàn bộ phần còn lại quyết định hệ thống chạy được hay không. <i>Đây là trọng tâm của đề.</i>
Tool / Function calling	Cơ chế cho LLM gọi hàm do lập trình viên định nghĩa (tra tồn kho, tạo đơn) thay vì tự bịa câu trả lời. LLM trả về tên hàm + tham số, code thật sự thực thi.
Guardrail	Lớp kiểm tra chặn agent làm điều không được phép — ở bài này là: không báo giá không có trong catalog, không hứa chính sách sai, không đọc thông tin cá nhân của khách khác.
Fallback	Phương án dự phòng khi có sự cố (tool lỗi, ASR trả rác): agent nói gì với khách, có chuyển người thật không, thay vì đứng im hoặc trả lời bừa.
Baseline	Phiên bản đối chứng đơn giản để so sánh. Ở đề này là hệ thống <i>không có bộ nhớ</i> . Không có baseline thì con số "chốt đơn 80%" không nói lên điều gì.
RAG	<i>Retrieval-Augmented Generation</i> . Trước khi trả lời, hệ thống tìm các đoạn tài liệu liên quan (chính sách, mô tả sản phẩm) rồi đưa vào prompt để LLM trả lời dựa trên đó — thay vì trả lời từ trí nhớ mơ hồ của model.
Embedding / Vector DB	Embedding biến đoạn text thành dãy số thể hiện ý nghĩa; Vector DB lưu và tìm nhanh các đoạn có ý nghĩa gần nhất với câu hỏi. Đây là nền tảng của RAG và của bộ nhớ ngữ nghĩa.
Recall@k	Trong k đoạn tài liệu mà hệ thống lấy ra, có bao nhiêu phần trăm trường hợp chứa được đoạn đúng cần thiết. Đo chất lượng khâu tìm kiếm của RAG, tách bạch với chất lượng câu trả lời.

Working / Episodic / Profile memory	Ba tầng bộ nhớ: <i>working</i> = ngữ cảnh trong lượt thoại hiện tại; <i>episodic</i> = tóm tắt từng cuộc gọi đã diễn ra; <i>profile</i> = những sự thật bền vững về khách (nhà bao nhiêu m², có con nhỏ).
TTL / decay	Thời hạn sống của một mẫu ký ức. Khuyến mãi hết hạn hay ý định mua từ 6 tháng trước không nên được dùng như thông tin còn giá trị.
Memory poisoning	Bộ nhớ bị ghi nhầm thông tin sai (khách nói đùa, người khác dùng chung số điện thoại) và từ đó về sau agent luôn hành xử dựa trên dữ kiện sai đó.
Identity resolution	Xác định các định danh khác nhau (số điện thoại, Zalo ID, Facebook ID, email) thực chất là cùng một người, để gộp ngữ cảnh lại.
Session / phiên	Một lần tương tác trọn vẹn (một cuộc gọi, một đoạn chat). Bài toán lõi của đề chính là giữ ngữ cảnh <i>xuyên qua ranh giới phiên</i> .
Call Brief	Bản tóm tắt ngắn về khách được nạp cho agent <i>ngay trước khi bắt máy</i> : đã tư vấn gì, báo giá bao nhiêu, còn vương gì, nên làm gì tiếp.
ASR / TTS / VAD / Diarization	ASR: nhận dạng giọng nói → text. TTS: text → giọng nói. VAD: phát hiện đoạn nào đang có tiếng nói. Diarization: tách xem câu nào của nhân viên, câu nào của khách.
ITN	<i>Inverse Text Normalization</i> — chuyển chữ viết ra thành ký hiệu chuẩn: " <i>bốn triệu tám trăm chín mươi nghìn</i> " → 4.890.000. Thiếu bước này thì số tiền và số điện thoại không dùng được để tạo đơn.
WER / CER	Tỷ lệ lỗi ASR ở mức từ / mức ký tự. Công thức ở Phụ lục A.5.
Hallucination	LLM nói ra thông tin nghe hợp lý nhưng sai sự thật — ở đây nguy hiểm nhất là bịa giá hoặc bịa khuyến mãi.
Few-shot / Exemplar	Đưa vài ví dụ mẫu vào prompt để LLM bắt chước cách làm, thay vì phải huấn luyện lại model.

LLM-as-a-judge	Dùng một LLM để chấm điểm đầu ra của hệ thống theo rubric định sẵn. Rẻ và nhanh hơn chấm tay, nhưng có thiên lệch nên phải đối chiếu với người trên một mẫu nhỏ.
Rubric	Bảng tiêu chí chấm cụ thể (đạt/không đạt từng mục), thay cho việc chấm cảm tính "cho mấy điểm trên 10".
Golden set / Regression suite	Bộ test chuẩn được giữ nguyên qua các vòng cải tiến, dùng để phát hiện khi sửa chỗ này lại làm hỏng chỗ kia.
Customer simulator	Một agent đóng vai khách hàng theo persona, để chạy thử hệ thống hàng chục lần một cách tự động và lặp lại được.
Ablation	Tắt bớt từng thành phần rồi đo lại, để biết thành phần nào thực sự tạo ra cải thiện chứ không chỉ trông có vẻ hữu ích.
Drift	Phân phối dữ liệu thực tế thay đổi theo thời gian (mùa sale, sản phẩm mới) khiến hệ thống dần kém đi dù code không đổi.

Human-in-the-loop	Có người duyệt trước khi hệ thống tự áp dụng một thay đổi — hàng rào an toàn cho vòng lặp tự cải tiến.
MCP	<i>Model Context Protocol</i> — chuẩn chung để agent kết nối tới nguồn dữ liệu và công cụ. Viết một "MCP server" cho CRM thì mọi agent đều dùng được, không phải viết lại tích hợp cho từng agent.
A2A / Multi-agent	Kiến trúc nhiều agent chuyên biệt cùng xử lý một nhiệm vụ, có giao thức để chuyển giao việc và chia sẻ trạng thái cho nhau.
PII	<i>Personally Identifiable Information</i> — thông tin định danh cá nhân: họ tên, số điện thoại, CCCD, địa chỉ, số tài khoản. Phải được che khi lưu log hoặc gửi ra dịch vụ bên ngoài.
p50 / p95	Phân vị độ trễ. p95 = 95% số lượt phản hồi nhanh hơn con số này. Dùng p95 thay vì trung bình vì trải nghiệm tệ nằm ở phần đuôi chậm.

C.2. Thuật ngữ nghiệp vụ call center / bán hàng

Telesale	Bán hàng qua điện thoại — nhân viên gọi ra hoặc nhận cuộc gọi đến để tư vấn và chốt đơn.
Lead	Khách hàng tiềm năng đã để lại thông tin liên hệ nhưng chưa mua.
Chốt đơn	Thuyết phục được khách đồng ý mua và tạo được đơn hàng.
Objection (phản đối)	Lý do khách viện ra để chưa mua: " <i>đắt quá</i> ", " <i>để hỏi vợ đã</i> ", " <i>bên kia rẻ hơn</i> ". Cách xử lý phản đối là kỹ năng cốt lõi của telesale.
Call script / Playbook	Kịch bản hội thoại mẫu mà nhân viên bám theo, gồm cả cách xử lý từng loại phản đối.
Upsell / Cross-sell	Bán phiên bản cao cấp hơn / bán thêm sản phẩm đi kèm.
Escalate (chuyển máy)	Chuyển cuộc gọi lên nhân viên có thẩm quyền hoặc từ bot sang người thật.
Handoff brief	Bản tóm tắt bàn giao khi chuyển máy, để người nhận không phải hỏi lại khách từ đầu (Case 3).
AHT	<i>Average Handling Time</i> — thời lượng trung bình xử lý một cuộc gọi. Giảm AHT mà vẫn giữ tỷ lệ chốt là mục tiêu vận hành quan trọng.
Calls-to-Close	Số cuộc gọi trung bình cần để chốt được một đơn. <i>Đây là chỉ số kinh tế trực tiếp nhất của bài toán trong đề.</i>
Conversion rate	Tỷ lệ khách được tư vấn thực sự mua hàng.
CSAT	<i>Customer Satisfaction</i> — điểm hài lòng khách chấm sau cuộc gọi.
QA (call center)	Bộ phận nghe lại ghi âm để chấm chất lượng cuộc gọi. Thực tế chỉ nghe được vài phần trăm — chính là vấn đề ở Case 4.
COD	<i>Cash on Delivery</i> — thanh toán khi nhận hàng. Phổ biến ở Việt Nam và có tỷ lệ hoàn hàng cao, nên việc chủ động xác nhận lại đơn rất quan trọng.

Hoàn hàng	Khách từ chối nhận, hàng bị trả về — shop chịu toàn bộ phí vận chuyển hai chiều.
SKU	Mã định danh một phiên bản sản phẩm cụ thể (đúng model, đúng màu, đúng size).
Hotline / OA / Fanpage	Các kênh khách liên hệ: tổng đài, Zalo Official Account, trang Facebook của shop. Ngữ cảnh bị phân mảnh giữa các kênh này chính là Case 2.
Pending queue	Hàng đợi các khách đã tư vấn nhưng chưa chốt, cần gọi lại chăm sóc.

— Hết đề —